FUNDAÇÃO EDSON QUEIROZ
UNIVERSIDADE DE FORTALEZA
Centro de Ciências Tecnológicas
Métodos Quantitativos em Computação

ATIVIDADE 3

CORRELAÇÃO E REGRESSÃO LINEAR

João Pedro Braga - Matrícula 2517424
João Pedro Eugenio Costa Rodrigues
Matrícula 2513839

Fortaleza - Ceará
Outubro de 2026

SUMÁRIO

1. Introdução 3

2. Análise e interpretação dos dados 3

2.1 Uso do celular 3

2.2 E-commerce 5

2.3 Aprendizagem de máquinas 6

3. Conclusão 8

4. Referências bibliográficas 8

1. INTRODUÇÃO

Este relatório apresenta um estudo quantitativo sobre as relações entre diferentes variáveis aplicadas a problemas reais. Utilizando os métodos de Correlação e Regressão Linear Simples, o objetivo é estabelecer modelos matemáticos que expliquem a dependência de uma variável (dependente) em relação a outra (independente). A correlação de Pearson é empregada para medir a força e a direção dessa relação linear.

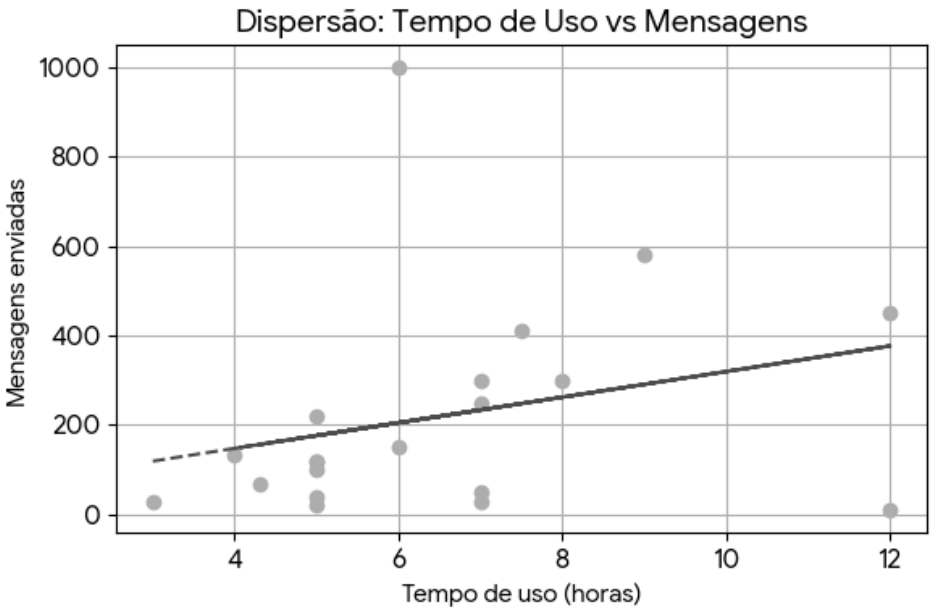
Avançando na complexidade, a Regressão Linear Múltipla é aplicada para avaliar o impacto simultâneo de múltiplas variáveis independentes sobre um único desfecho. Essa técnica é fundamental em Ciência de Dados para entender configurações de treinamento, evitar *overfitting* e otimizar recursos.

2. ANÁLISE E INTERPRETAÇÃO DOS DADOS

2.1 Situação problema 1: Uso do celular

Com base na pesquisa de campo realizada com 20 estudantes, relacionamos o Tempo de Uso diário do celular em horas (X) e a Quantidade de Mensagens enviadas (Y).

a) Gráfico de dispersão



2.1 Uso do celular (continuação)

b) Reta de regressão: A equação encontrada é: Y = 33.62 + 28.59X.

c) Coeficiente angular: O coeficiente angular (b = 28.59) indica que, em média, para cada 1 hora a mais de uso do celular, o estudante envia aproximadamente 29 mensagens adicionais. (Obs.: A presença de um *outlier* como 999 mensagens puxa a inclinação.)

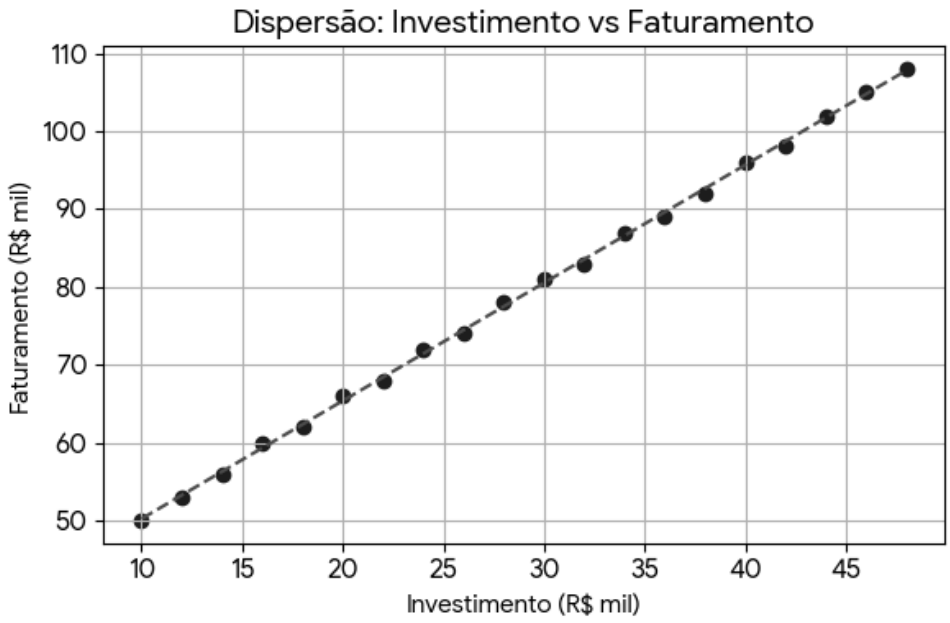
d) Estimativas: Utilizando o modelo gerado:
Para 2h de uso: 90.81 mensagens.
Para 4h de uso: 148.00 mensagens.
Para 6h de uso: 205.19 mensagens.

e) Coeficientes: r = 0.2805 e R^2 = 0.0787. O modelo explica apenas 7.87% das variações. Devido à grande variabilidade (ex.: pessoas que usam 12h enviando 10 mensagens versus pessoas usando 6h enviando 999), a correlação é considerada fraca e o modelo não explica muito bem os dados perfeitamente.

2.2 Situação problema 2: E-commerce

Nesta análise, avalia-se o impacto do investimento em marketing digital (X) no faturamento de e-commerce (Y).

a) Gráfico de dispersão



b) Tipo de relação: O gráfico evidencia uma clara relação linear positiva entre o investimento e o faturamento. O crescimento de uma variável acompanha o crescimento da outra.

c) Coeficiente de correlação (Pearson): r = 0.9996.

d) Intensidade: Correlação positiva muito forte, quase perfeita (próxima de 1).

e) Interpretação: O aumento do investimento em campanhas digitais está diretamente e fortemente associado ao aumento das vendas da empresa.

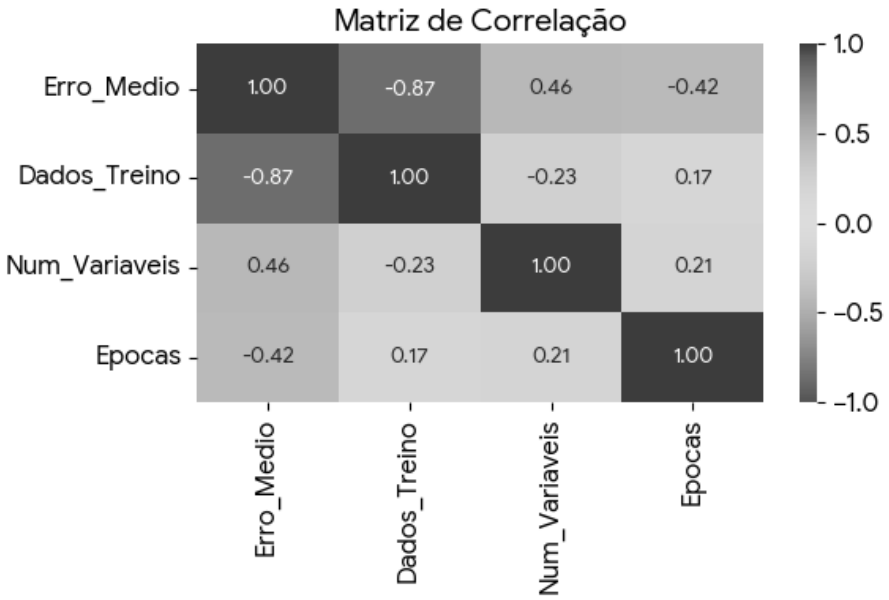
f) Coeficiente de determinação (R^2): R^2 = 0.9993. O modelo explica 99.93% das variações ocorridas no faturamento.

g) Estimativa de faturamento: Para um investimento de R$ 50 mil, o faturamento estimado é de R$ 110.82 mil.

2.3 Situação problema 3: Aprendizagem de máquinas

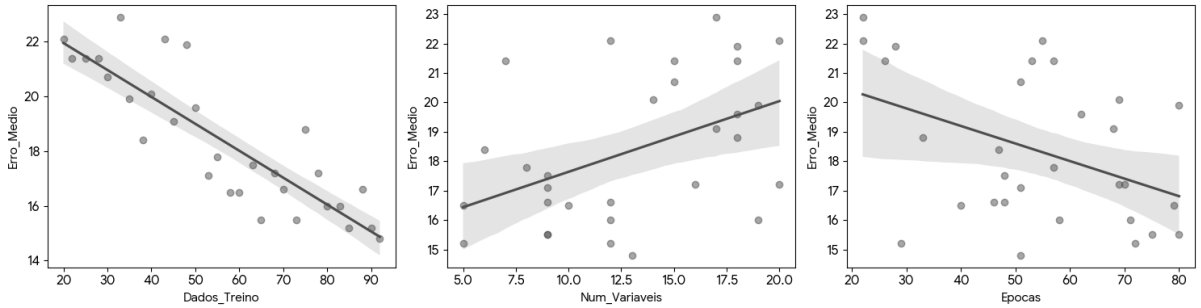
2.3.1 Análise exploratória

Matriz de correlação



Há uma correlação forte negativa (-0.79) entre o volume de dados e o erro. As variáveis e as épocas apresentam correlações menores com o erro médio.

Gráficos de dispersão



2.3.2 Modelo de regressão linear múltipla

A equação gerada pelo modelo é:

Erro_Medio = 23.2981 - 0.0816 × (Dados_Treino)
+ 0.1966 × (Num_Variaveis) - 0.0536 × (Epocas)

2.3.3 Qualidade do ajuste do modelo

R^2: 0.9550 | R^2 ajustado: 0.9498

Os indicadores representam que cerca de 95.50% da variância do Erro Médio é explicada pelas configurações do experimento. O R^2 ajustado penaliza a inclusão de variáveis desnecessárias e corrobora a robustez do modelo.

2.3.4 Significância estatística

Teste F (p-valor): 1.2755e-17. Sendo menor que 0,05, o modelo global é estatisticamente válido.

Significância das variáveis (p-valores):
Dados_Treino: 3.0351e-15 (Significativo)
Num_Variaveis: 6.2886e-09 (Significativo)
Epocas: 0.0000 (Não Significativo, > 0,05)

2.3.5 Importância relativa das variáveis

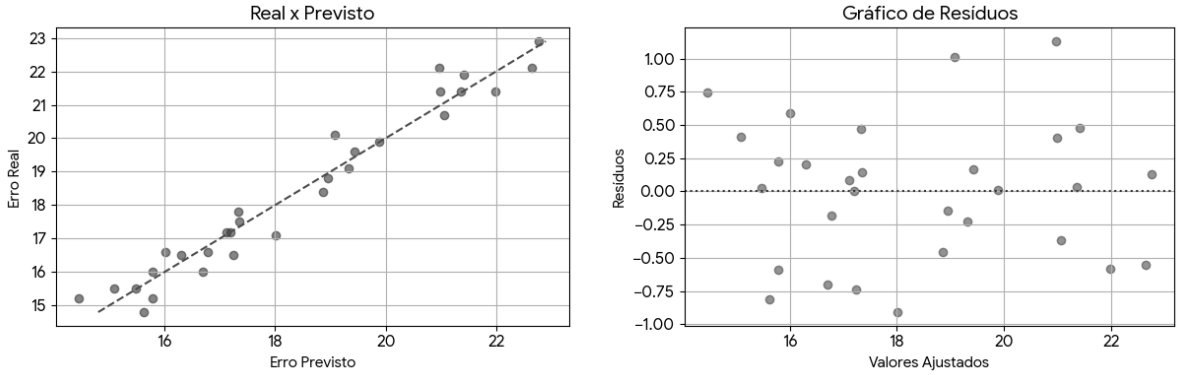
Os coeficientes padronizados revelam a real importância isolada das variáveis, contornando a diferença de escalas (milhares de registros versus dezenas de épocas):

Dados_Treino: -0.7200
Num_Variaveis: 0.3733
Epocas: -0.3788

A quantidade de Dados de Treino possui o maior peso absoluto, sendo a variável mais importante para explicar as flutuações no erro do modelo.

2.3.6 Previsão e avaliação

Para uma nova configuração com Dados de Treino = 65 mil, 12 Variáveis e 60 Épocas, o erro estimado pelo modelo é de 17.1375.



O gráfico Real x Previsto demonstra pontos ajustados próximos à diagonal, enquanto o gráfico de resíduos apresenta dispersão aleatória sem padrões óbvios (homocedasticidade), confirmando a adequação do modelo preditivo para tomada de decisão na configuração de treinamentos.

3. CONCLUSÃO

Este relatório comprovou a aplicabilidade prática da estatística na resolução de problemas. Na Situação 1, notamos que o uso do celular nem sempre garante alta troca de mensagens devido à dispersão dos hábitos dos alunos. Já na Situação 2, validou-se que investimentos em marketing são determinantes confiáveis para prever o faturamento do E-commerce. Por fim, no cenário de Machine Learning (Situação 3), o modelo evidenciou que obter mais dados de treino é muito mais eficaz para diminuir o erro do que adicionar épocas de treinamento, apontando diretrizes valiosas para Ciência de Dados.

4. REFERÊNCIAS BIBLIOGRÁFICAS

MONTGOMERY, Douglas C. et al. **Estatística Aplicada e Probabilidade para Engenheiros.** 5. ed. Rio de Janeiro: LTC, 2012.

Material de Apoio da Disciplina - Métodos Quantitativos em Computação. Universidade de Fortaleza, 2026.