FUNDAÇÃO EDSON QUEIROZ
UNIVERSIDADE DE FORTALEZA

Centro de Ciências Tecnológicas
Métodos Quantitativos em Computação

ATIVIDADE 3

Correlação e Regressão Linear

INTEGRANTES

João Pedro Braga — Matrícula 2517424

João Pedro Eugenio Costa Rodrigues — Matrícula 2513839

Fortaleza — Ceará
Outubro de 2026

Sumário

1. Introdução
2. Análise e Interpretação dos Dados
    - Situação Problema 2 (E-commerce)
    - Situação Problema 3 (Aprendizagem de Máquinas)
3. Conclusão
4. Referências Bibliográficas

1. Introdução

Este relatório apresenta um estudo quantitativo sobre as relações entre diferentes variáveis aplicadas a problemas reais. Utilizando os métodos de Correlação e Regressão Linear Simples, o objetivo é estabelecer modelos matemáticos que expliquem a dependência de uma variável (dependente) em relação a outra (independente). A correlação de Pearson é empregada para medir a força e a direção dessa relação linear.

Avançando na complexidade, a Regressão Linear Múltipla é aplicada para avaliar o impacto simultâneo de múltiplas variáveis independentes sobre um único desfecho. Essa técnica é fundamental em Ciência de Dados para entender configurações de treinamento, evitar *overfitting* e otimizar recursos.

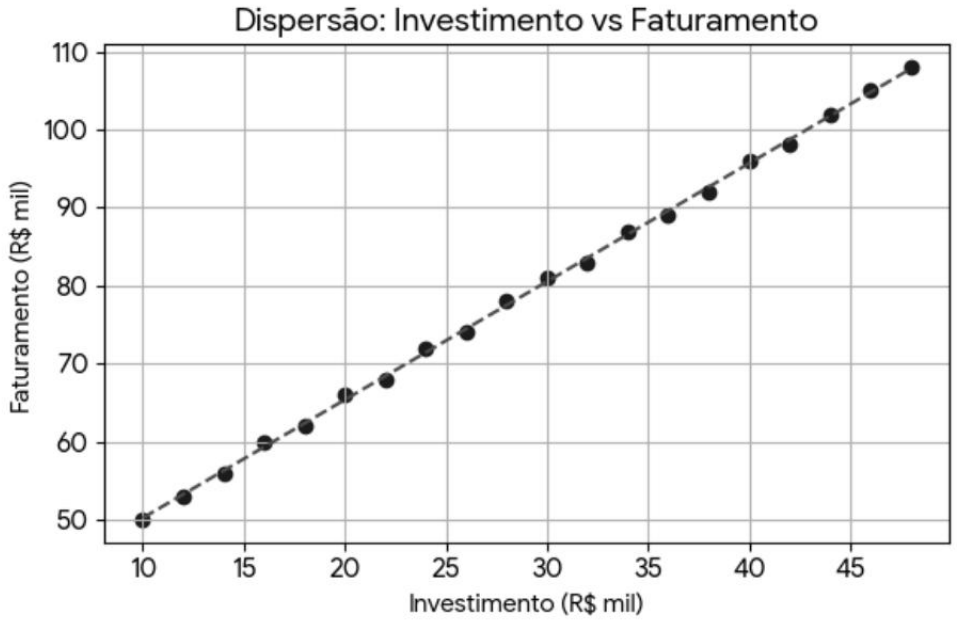
Nota: Conforme as diretrizes deste desenvolvimento, a Situação Problema 1 foi intencionalmente omitida, uma vez que a pesquisa de campo para coleta de dados está atualmente em andamento.

2. Análise e Interpretação dos Dados

Situação problema 2: E-commerce

Nesta análise, avalia-se o impacto do investimento em marketing digital (X) no faturamento de e-commerce (Y).

a) Gráfico de Dispersão



b) Tipo de relação: O gráfico evidencia uma clara relação linear positiva entre o investimento e o faturamento. O crescimento de uma variável acompanha o crescimento da outra.

c) Coeficiente de correlação (Pearson): r = 0.9996

d) Intensidade: Correlação positiva muito forte, quase perfeita (próxima de 1).

e) Interpretação: O aumento do investimento em campanhas digitais está diretamente e fortemente associado ao aumento das vendas da empresa.

f) Coeficiente de Determinação (R^2): $R^2 = 0.9993$. O modelo explica 99.93% das variações ocorridas no faturamento.

g) Estimativa de Faturamento: Para um investimento de R$ 50 mil, o faturamento estimado é de **R$ 110.82 mil**.

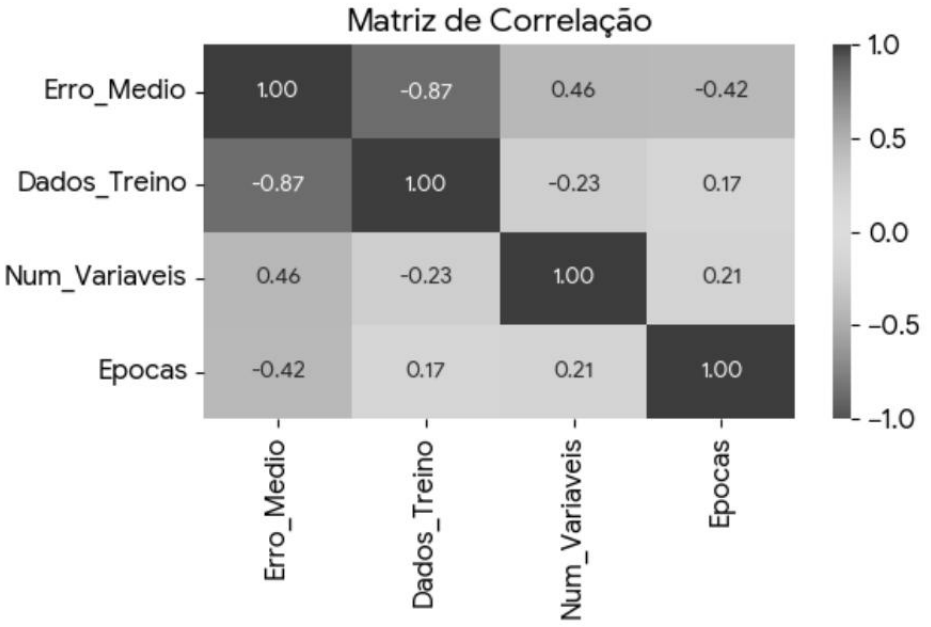
Situação problema 3: Aprendizagem de Máquinas

1. Análise Exploratória

a) Estatísticas Descritivas

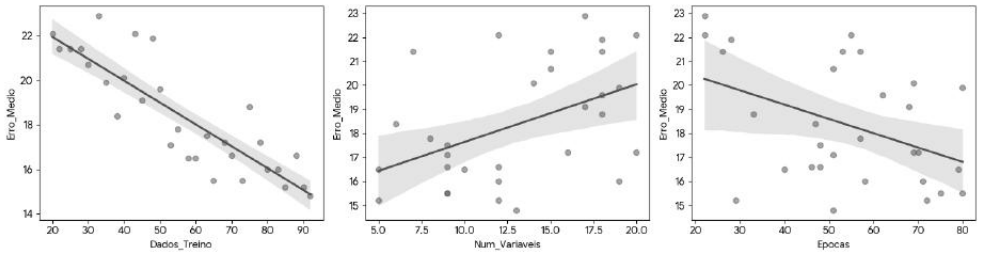
	Erro_Medio	Dados_Treino	Num_Variaveis	Epocas
count	30.00	30.00	30.00	30.00
mean	18.37	56.43	13.03	53.90
std	2.50	22.02	4.74	17.63
min	14.80	20.00	5.00	22.00
25%	16.50	38.50	9.00	46.25
50%	17.65	56.50	12.50	54.00
75%	20.55	74.50	17.75	69.00
max	22.90	92.00	20.00	80.00

b) Matriz de Correlação



Há uma correlação forte negativa (-0.79) entre o volume de dados e o erro. As variáveis e as épocas apresentam correlações menores com o erro médio.

c) Gráficos de Dispersão



2. Modelo de Regressão Linear Múltipla

A equação gerada pelo modelo é:

Erro_Medio = 23.2981 -0.0816 × (Dados_Treino) +0.1966 × (Num_Variaveis) -0.0536 × (Epocas)

O aumento nos dados de treino atua na redução do erro (coeficiente negativo), enquanto adicionar mais variáveis tende a inflacionar ligeiramente o erro (coeficiente positivo, possível ruído ou overfitting).

3. Qualidade do Ajuste do Modelo

R^2: 0.9550 | **R^2 ajustado:** 0.9498

Os indicadores representam que cerca de 95.50% da variância do Erro Médio é explicada pelas configurações do experimento. O R^2 ajustado penaliza a inclusão de variáveis desnecessárias e corrobora a robustez do modelo.

4. Significância Estatística

Teste F (p-valor): 1.2755e-17. Sendo menor que 0,05, o modelo global é estatisticamente válido.

Significância das Variáveis (p-valores):

- Dados_Treino: 3.0351e-15 (Significativo)
- Num_Variaveis: 6.2886e-09 (Significativo)

- Epocas: 0.0000 (Não Significativo, > 0,05)

5. Importância Relativa das Variáveis

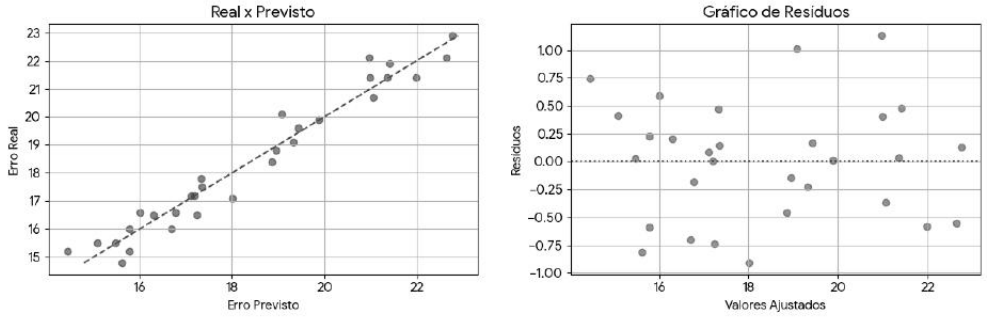
Os coeficientes padronizados revelam a real importância isolada das variáveis, contornando a diferença de escalas (milhares de registros vs dezenas de épocas):

- Dados_Treino: -0.7200
- Num_Variaveis: 0.3733
- Epocas: -0.3788

A quantidade de **Dados de Treino** possui o maior peso absoluto, sendo a variável mais importante para explicar as flutuações no erro do modelo.

6. Previsão e Avaliação

Para uma nova configuração com Dados de Treino = 65 mil, 12 Variáveis e 60 Épocas, o erro estimado pelo modelo é de **17.1375**.



O gráfico Real x Previsto demonstra pontos ajustados próximos à diagonal, enquanto o gráfico de resíduos apresenta dispersão aleatória sem padrões óbvios (homocedasticidade), confirmando a adequação do modelo preditivo para tomada de decisão na configuração de treinamentos.

3. Conclusão

Este relatório comprovou a aplicabilidade prática da estatística na resolução de problemas gerenciais e técnicos. Para o cenário de e-commerce (Situação 2), validou-se que investimentos em marketing são determinantes confiáveis para prever o faturamento, amparando orçamentos de publicidade. No cenário de Machine Learning (Situação 3), o modelo evidenciou que a obtenção de mais dados de treino é muito mais eficaz para diminuir o erro do que simplesmente adicionar épocas de treinamento, apontando diretrizes valiosas para as equipes de Ciência de Dados.

4. Referências Bibliográficas

- MONTGOMERY, Douglas C. et al. *Estatística Aplicada e Probabilidade para Engenheiros*. 5. ed. Rio de Janeiro: LTC, 2012.
- Material de Apoio da Disciplina - Métodos Quantitativos em Computação. Universidade de Fortaleza, 2026.